

- ResMLP_transport 实验记录
 - 1. 实验目标
 - 2. 模型结构
 - 3. 训练策略
 - 4. 最新训练结果 (2026-04-09 04:19:54)
 - 4.1 总体结果
 - 4.2 各目标 RMSE 对比
 - 4.3 各目标 MAE
 - 4.4 关键观察
 - 5. 非线性修正质量
 - 6. 可视化结果
 - 6.1 相对 RMSE 对比
 - 6.2 训练 / 验证 Loss 曲线
 - 6.3 Parity 图
 - 6.4 Residual 分布
 - 6.5 非线性修正 Parity 图
 - 7. 结果解读
 - 8. 关联产物
 - 9. 一句话总结

ResMLP_transport 实验记录

- 日期: 2026-04-09
- Notebook:
SHMS_Calibration_NN/experiments/ResMLP/ResMLP_transport.ipynb
- 最新运行标签: 20260409_041954

1. 实验目标

ResMLP_transport 的目标是构建一个不依赖 ROOT 重建结果作为训练 baseline 的 SHMS optics 重建模型。

与之前的 ROOT-residual 方案不同, 这个版本不再训练

- $y_{\text{truth}} - y_{\text{ROOT}}$

而是直接在网络内部做结构分解:

- 线性 transport 主干负责学习 spectrometer 的零阶 / 一阶近似；
- 残差分支负责学习高阶非线性修正；
- 最终输出满足

$$y = y_{\text{linear}} + y_{\text{correction}}$$

这样做的核心思想是 **perturbation learning**：让模型先搭建可解释的线性骨架，再由残差分支补偿 fringe field、aberration 和更复杂的非线性项。

2. 模型结构

当前 **ResMLP_transport** 由三部分组成：

1. Linear path

- 一个从输入到输出的线性层；
- 代表零阶 / 一阶 transport map；
- 使用训练集最小二乘解进行初始化，而不是随机初始化。

2. Residual nonlinear branch

- 先经过一个输入投影层；
- 然后进入多个 residual block；
- 每个 block 内部采用 skip connection，改善梯度传播与收敛稳定性。

3. Correction head

- 输出非线性修正项；
- 与线性主干输出相加得到最终结果。

简化后的结构可以写成：

$$\hat{y} = W_{\text{linear}}x + f_{\text{residual}}(x)$$

其中：

- $W_{\text{linear}}x$ 是线性 transport；
- $f_{\text{residual}}(x)$ 是高阶非线性修正。

3. 训练策略

本次运行使用了以下关键设置：

- 数据文件：mc-single-arm/worksim/shms_extended_nosieve.root
- 树名：h10
- 模式：all
- 输入特征：x_fp, y_fp, xp_fp, yp_fp, x_tar, p0
- 输出目标：delta, xptar, yptar, ytar
- 事件数：100000
- 训练 / 验证划分：80000 / 20000
- Batch size：2048
- 学习率：8e-4
- Weight decay：1e-4
- Hidden dim：192
- Residual blocks：4
- Dropout：0.10
- 线性层初始化：最小二乘 + ridge=1e-6
- 训练前 10 个 epoch：只训练线性主干
- 之后冻结线性主干，只训练非线性修正分支
- 损失函数：加权 SmoothL1
- ytar loss weight：0.5
- 非线性修正 L2 正则：1e-4
- 早停：patience = 15

4. 最新训练结果（2026-04-09 04:19:54）

4.1 总体结果

- best_epoch = 54
- best_val_loss = 0.003684
- n_train = 80000
- n_val = 20000

4.2 各目标 RMSE 对比

Target	Linear path RMSE	Transport ResMLP RMSE	ROOT reco RMSE	ResMLP 相对线性提升
delta	3.352445	0.458363	0.316723	86.33%
xptar	0.009182	0.002699	0.002300	70.61%
yptar	0.007472	0.001563	0.001544	79.08%
ytar	11.370134	1.809712	2.006163	84.08%

4.3 各目标 MAE

Target	ResMLP MAE	ROOT reco MAE
delta	0.329776	0.147366
xptar	0.001542	0.001191
yptar	0.001043	0.001048
ytar	1.237103	1.443438

4.4 关键观察

1. 模型已经完全脱离 ROOT residual baseline 训练，这是本实验最重要的结构性成果。
2. **ytar** 已经优于 ROOT reco：
 - ResMLP RMSE = **1.809712**
 - ROOT reco RMSE = **2.006163**
3. 对 **delta** / **xptar** / **yptar**，当前版本仍略弱于 ROOT reco，但已经明显优于内部线性主干。
4. 线性主干本身仍然比较粗糙，说明对于当前输入特征而言，**delta** 和 **ytar** 的有效映射中仍存在较强非线性。

5. 非线性修正质量


非线性真值项与预测 correction 的相关性（来自诊断输出）为：

Target	corr(true nonlinear, predicted correction)
delta	0.9904
xptar	0.9554
yptar	0.9777
ytar	0.9871


这说明残差分支确实在学习高阶修正，而不是简单重复线性主干的功能。

6. 可视化结果


6.1 相对 RMSE 对比




6.2 训练 / 验证 Loss 曲线




6.3 Parity 图



6.4 Residual 分布



6.5 非线性修正 Parity 图



7. 结果解读

从当前结果看，这个结构已经达到了两个关键目的：

- 结构上独立于 ROOT 重建；
- 数值上成功学到了有效的非线性 correction。

尤其是 **ytar** 的改进比较有代表性：它说明即使不把 ROOT 结果作为训练 baseline，网络仍然能依靠内部线性路径 + 残差修正的方式恢复有物理意义的重建关系。

不过，要让该模型在所有目标上全面超过 ROOT reco，后续仍建议继续强化：

- 线性主干的物理约束；
- **delta** 的专门优化；
- 更强的多头输出或 target-specific correction branch；
- 更贴近 optics transport 的显式矩阵参数化。

8. 关联产物

- 指标
JSON: `../outputs_transport_skip/transport_resmlp_metrics_all_20260409_041954.json`
- 指标
CSV: `../outputs_transport_skip/transport_resmlp_metrics_all_20260409_041954.csv`
- Notebook: `../ResMLP_transport.ipynb`

9. 一句话总结

ResMLP_transport 已经成功实现了“**线性 transport + 非线性残差修正**”的 ROOT 无关训练框架，并在 ytar 上取得了优于 ROOT reco 的结果，是一个可继续物理化和精细化优化的有效基线。